


Series de tiempo no estacionarias

Felipe Yépez

2022-12-02

Venta de Televisores


```
t = 1:16
ventas = c(4.8, 4.1, 6.0, 6.5, 5.8, 5.2, 6.8, 7.4, 6.0, 5.6, 7.5, 7.8, 6.3, 5.9, 8.0, 8.4)
plot(t, ventas, type="o", col="red", main="Ventas (Miles)")
```



Existe tendencia alcista en la gráfica con ciclos de 4 trimestres.

```
x=ts(ventas, frequency = 4, start=c(2016,1))
T = decompose(x, type = "m")
plot(T, col="blue")
```

Decomposition of multiplicative time series



Se trata de una serie no estacionaria ya que existe tendencia en la gráfica que va en aumento.

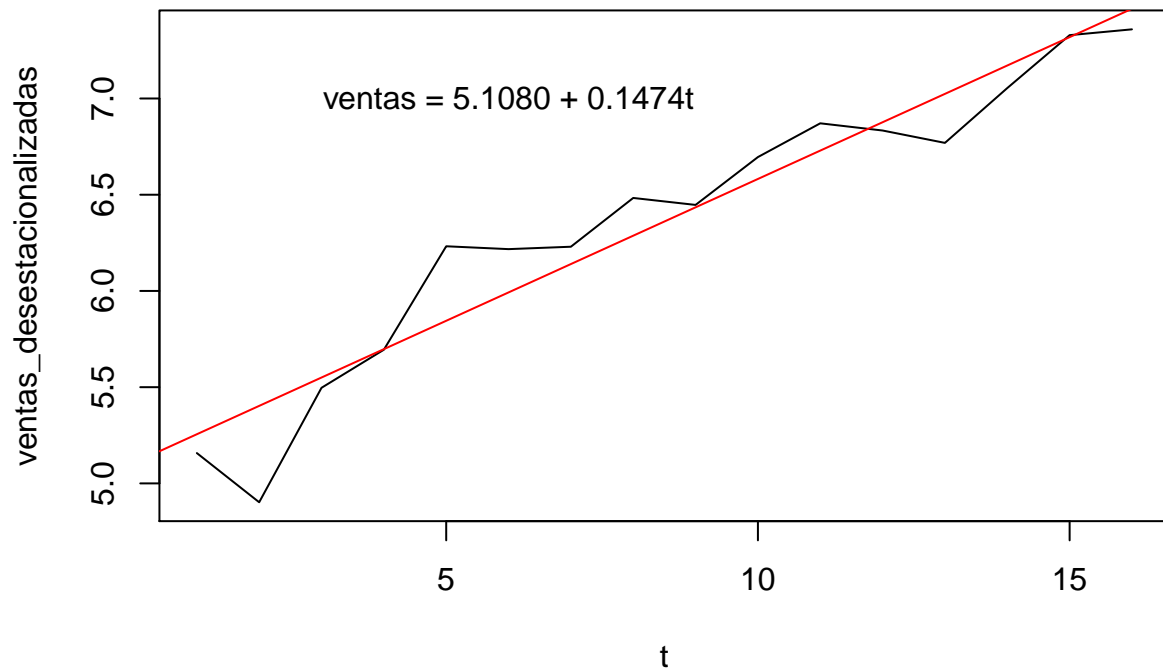
En la gráfica de Observed se pueden visualizar los valores originales de la serie de tiempo.

Seasonal muestra la tendencia estacional mientras que random muestra la tendencia aleatoria, es decir los errores entre lo predicho en la tendencia estacional y lo observado.

```
ventas_desestacionalizadas = (T$x)/(T$seasonal)
reg = lm(ventas_desestacionalizadas~t)
reg
```

```
##
## Call:
## lm(formula = ventas_desestacionalizadas ~ t)
##
## Coefficients:
## (Intercept)          t
##      5.1080      0.1474
```

```
plot(t, ventas_desestacionalizadas, type="l")
abline(reg, col="red")
text(6,7, "ventas = 5.1080 + 0.1474t")
```



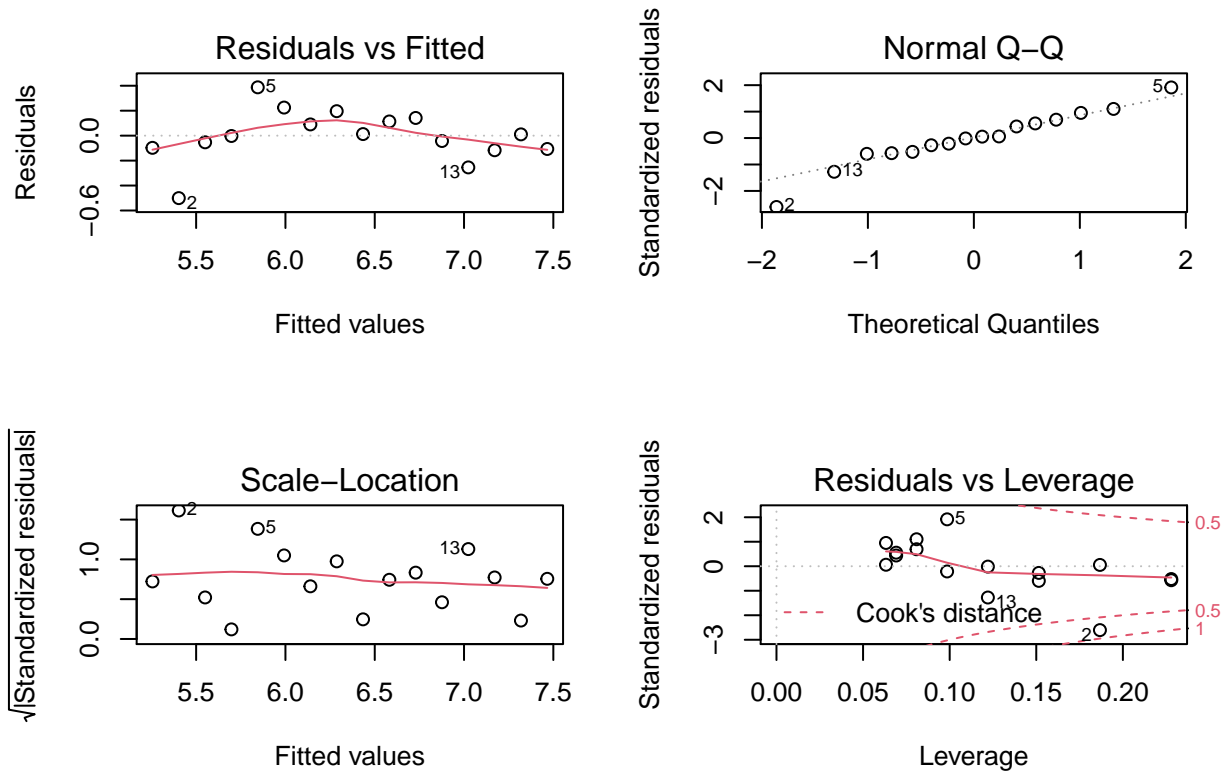
```
summary(reg)
```

```
##
## Call:
## lm(formula = ventas_desestacionalizadas ~ t)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.5007 -0.1001  0.0037  0.1207  0.3872
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  5.10804    0.11171   45.73  < 2e-16 ***
## t            0.14738    0.01155   12.76 4.25e-09 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.213 on 14 degrees of freedom
## Multiple R-squared:  0.9208, Adjusted R-squared:  0.9151
## F-statistic: 162.7 on 1 and 14 DF,  p-value: 4.248e-09
```

Se puede observar según los p valores obtenidos que el modelo es significativo ya que se puede rechazar la hipótesis nula de que B1 es diferente de 0 y por lo tanto existe dependencia en el modelo. Los p valores no superan el valor de significancia $\alpha = 0.05$

Se obtiene un valor R cuadrada de 0.9208 por lo que la variabilidad explicada por el modelo es alta, superando el 90%. Y una R cuadrada ajustada de 0.9151


```
par(mfrow=c(2,2))
plot(reg)
```



Se puede observar en las anteriores gráficas de residuos que existe normalidad en el conjunto de datos. El QQPlot muestra normalidad

```
hist(reg$residuals)
lines(density(reg$residuals), col="red")
```

Histogram of reg\$residuals



Existe poco de sesgo a la izquierda en la distribución de los residuos.

```
t.test(reg$residuals)
```

```
##
## One Sample t-test
##
## data: reg$residuals
## t = -1.4751e-16, df = 15, p-value = 1
## alternative hypothesis: true mean is not equal to 0
## 95 percent confidence interval:
## -0.1096629 0.1096629
## sample estimates:
## mean of x
## -7.589415e-18
```

Sale un valor muy cercano a 0 para la media de residuos.

```
CME = mean(ventas_desestacionalizadas ^ 2, na.rm = TRUE)
CME
```

```
## [1] 40.96092
```

Se obtiene un CME de 40.96 para el promedio móvil.

En general el modelo es bueno por los anteriores hallazgos, se ajusta y explica la variabilidad de la venta de televisores y existe normalidad en los datos. El modelo tiene dependencia con sus variables.

Pronóstico para el siguiente año

```
f = function(x) {5.1080 + 0.1474*x}
a1 = T$seasonal[1]
a2 = T$seasonal[2]
a3 = T$seasonal[3]
a4 = T$seasonal[4]
f(17)*a1
```

```
## [1] 7.085872
```

```
f(18)*a2
```

```
## [1] 6.491284
```

```
f(19)*a3
```

```
## [1] 8.632585
```

```
f(20)*a4
```

```
## [1] 9.195263
```

Se obtienen las predicciones para los 4 trimestres del siguiente año en (miles).

Un Problemilla más

```
PM = NA
PMC = NA
trimestre = c(1,2,3,4,1,2,3,4,1,2,3,4)
y = c(1690, 940, 2625, 2500, 1800, 900, 2900, 2360, 1850, 1100, 2930, 2615)
for(i in 1:(length(y) - 1)){
  PM[i+1] = (y[i]+y[i+1]+y[i+2]+y[i+3])/4;
}
for(i in 1:(length(PM)-1)){
  PMC[i+1] = (PM[i] + PM[i+1])/2;
}
ValEstIrregular = y/PMC
T = data.frame(trimestre,y, PM, PMC, ValEstIrregular)
T
```

```
##   trimestre    y      PM      PMC ValEstIrregular
## 1         1 1690      NA      NA              NA
## 2         2  940 1938.75      NA              NA
## 3         3 2625 1966.25 1952.500      1.3444302
## 4         4 2500 1956.25 1961.250      1.2746973
## 5         1 1800 2025.00 1990.625      0.9042386
```

```
## 6      2  900 1990.00 2007.500      0.4483188
## 7      3 2900 2002.50 1996.250      1.4527239
## 8      4 2360 2052.50 2027.500      1.1639951
## 9      1 1850 2060.00 2056.250      0.8996960
## 10     2 1100 2123.75 2091.875      0.5258440
## 11     3 2930      NA      NA      NA
## 12     4 2615      NA      NA      NA
```

Índice Estacional

```
IE1 = mean(T$ValEstIrregular[T$trimestre == 1 & !is.na(T$ValEstIrregular)])
IE2 = mean(T$ValEstIrregular[T$trimestre == 2 & !is.na(T$ValEstIrregular)])
IE3 = mean(T$ValEstIrregular[T$trimestre == 3 & !is.na(T$ValEstIrregular)])
IE4 = mean(T$ValEstIrregular[T$trimestre == 4 & !is.na(T$ValEstIrregular)])
cat("Índice estacional Trimestre 1 = ", IE1, "\n")
```

```
## Índice estacional Trimestre 1 = 0.9019673
```

```
cat("Índice estacional Trimestre 2 = ", IE2, "\n")
```

```
## Índice estacional Trimestre 2 = 0.4870814
```

```
cat("Índice estacional Trimestre 3 = ", IE3, "\n")
```

```
## Índice estacional Trimestre 3 = 1.398577
```

```
cat("Índice estacional Trimestre 4 = ", IE4, "\n")
```

```
## Índice estacional Trimestre 4 = 1.219346
```